

Продвинутые методы дифференциальной приватности

Маслов Матвей

Ноябрь 2025

1 Введение

В задачах анализа данных часто требуется вычислять различные статистики по чувствительным данным. Пусть имеется датасет X , состоящий из n записей. Под *соседними* датасетами X и X' понимают такие датасеты, которые отличаются ровно одной записью. Это определение является ключевым, поскольку дифференциальная приватность формализует устойчивость алгоритма к изменению **одного** человека в выборке.

Определение 1.1 (ϵ -дифференциальная приватность). Алгоритм $A : X \rightarrow Y$ называется ϵ -дифференциально приватным, если для любых двух соседних датасетов X и X' и любого измеримого множества $S \subseteq Y$ выполняется:

$$\Pr[A(X) \in S] \leq e^\epsilon \Pr[A(X') \in S].$$

Интуитивно: присутствие одного человека в данных почти не влияет на выход алгоритма.

1.1 Чувствительность функции

Часто алгоритм описывается как $A(X) = f(X) + \text{noise}$. Тогда важна чувствительность f :

Определение 1.2 (L1-чувствительность). L1-чувствительность функции f определяется как:

$$\Delta_1 f = \max_{X, X'} \|f(X) - f(X')\|_1,$$

где максимум берётся по соседним X и X' .

1.2 Лапласовский механизм

Определение 1.3 (Лапласовский механизм). Пусть f — рандомизированный алгоритм (например ml -модель). Тогда

$$A(X) = f(X) + \eta, \quad \eta \sim Lap(0, b), \quad b = \frac{\Delta_1 f}{\varepsilon}.$$

Теорема 1.1 (Лапласовский механизм является ε -DP). Лапласовский механизм с параметром $b = \Delta_1 f / \varepsilon$ обеспечивает ε -дифференциальную приватность.

Такой шум с некоторыми изменениями можно добавлять в саму ml -модель, в функцию потерь для ml -модели и, что используют чаще всего, в градиент при обучении ml -модели.

1.3 Теорема композиции

Теорема 1.2 (Базовая композиция). Если алгоритмы $A_1, A_2, \dots, A_k$ являются $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_k$ -DP соответственно, то алгоритм

$$A(X) = (A_1(X), \dots, A_k(X))$$

обеспечивает

$$\varepsilon = \sum_{i=1}^k \varepsilon_i\text{-DP}.$$

То есть каждое применение расходует часть бюджета приватности.

Теорема 1.3 (Пост-процессинг). Если A — ε -DP и g — любая (в том числе случайная) функция, не использующая исходные данные напрямую, то

$$g(A(X))$$

остаётся ε -DP.

1.4 А какой ε взять и на что это влияет?

Из определения ε -DP не сложно понять, что при уменьшение ε точность алгоритма будет падать, но будет расти его приватность, т.к. в этом случае данные будут слабо отличимы. И наоборот при увеличении ε точность алгоритма будет расти, но будет падать его приватность. На практике ε берут порядка $0.1 \sim 5$. Apple и Google используют $\varepsilon = 1 \sim 2$.

2 Атаки на приватность: Membership и Reconstruction

2.1 Membership inference attack

Пусть имеется датасет X и обученная на нём модель или статистический алгоритм A , к которому злоумышленник имеет доступ. Также есть человек с данными x .

Атака на принадлежность формально определяется как задача различения двух гипотез:

$$H_0 : x \notin X, \quad H_1 : x \in X.$$

Злоумышленник наблюдает ответы алгоритма $A(D)$ и строит статистический тест

$$T(A(X), x) \in \{0, 1\},$$

где 1 означает «запись находится в датасете», а 0 — «записи нет».

Если алгоритм не защищён, точность такого теста может существенно превышать случайное угадывание (0.5). Если механизм удовлетворяет ε -DP, то различимость между H_0 и H_1 фундаментально ограничена:

$$\Pr[A(X) \in S] \leq e^\varepsilon \Pr[A(X') \in S],$$

где X' — любая выборка, отличающаяся одним элементом.

Это означает, что вероятность успешной атаки ограничена и не может быть значительно выше случайного угадывания.

2.2 Reconstruction attack

Пусть датасет состоит из n записей:

$$X = (x_1, x_2, \dots, x_n).$$

Злоумышленник может выполнять к алгоритму A множество статистических запросов:

$$q_1, q_2, \dots, q_k,$$

например, средние значения, суммы, доли единиц и т. д.

Алгоритм выдаёт ответы:

$$a_i = A(X, q_i).$$

Атака восстановления — это процедура, которая по набору запросов и ответов строит оценку:

$$\hat{X} = f(a_1, \dots, a_k),$$

такую, что $\hat{X}$ хорошо приближает оригинальный датасет X .

Классический результат Dinur & Nissim утверждает что, если ответы на запросы слишком точные и злоумышленник может сделать достаточно много запросов, то восстановление возможно вплоть до точных значений отдельных элементов x_i .

Иначе говоря, «слишком точные агрегаты» эквивалентны раскрытию данных.

Как этому мешает дифференциальная приватность?

Механизм, удовлетворяющий ϵ -DP, добавляет шум с дисперсией, растущей с количеством запросов (из-за композиции):

$$\text{Var}(\text{шум}) \sim k.$$

В результате ошибка восстановления имеет фундаментальную нижнюю границу: точное восстановление становится невозможным, а оценка $\hat{X}$ всё дальше от истинного X при увеличении k .

3 Продвинутое методы 1: Функция стоимости, экспоненциальный механизм и зашумленный максимум

3.1 Зачем нужны такие механизмы: мотивация и примеры

Многие задачи анализа данных требуют выбирать лучший результат среди множества вариантов: лучший параметр модели, наиболее популярный элемент, наиболее вероятную категорию, оптимальный порог классификации, набор признаков с максимальной важностью и т. д. Простое добавление лапласовского шума к каждому кандидату часто не обеспечивает необходимого баланса между точностью и приватностью.

Например нам нужно выбрать самого лучшего кандидата на выборах. Или у нас есть набор цен на большое количество продуктов, тогда мы можем сильно потерять в точности и выбрать например не самый лучший продукт.

В этом случае нам могут помочь экспоненциальный механизм и механизм poisy max , которые предлагают приватный способ выбора результата, контролируя утечку через чувствительность функции стоимости.

3.2 Чувствительность функции стоимости

Пусть есть пространство результатов R .

Определение 3.1. Функция стоимости $u(X, r)$ измеряет, насколько результат $r \in R$ хорош для датасета X . Её чувствительность:

$$\Delta u = \max_{r, X, X'} |u(X, r) - u(X', r)|,$$

где X и X' — соседние датасеты.

3.3 Экспоненциальный механизм

Определение 3.2 (Экспоненциальный механизм). Пусть $u(X, r)$ — функция стоимости. Экспоненциальный механизм выбирает результат r с вероятностью

$$\Pr[A(X) = r] \sim \exp\left(\frac{\varepsilon u(X, r)}{2\Delta u}\right).$$

Теорема 3.1. Экспоненциальный механизм является ε -дифференциально приватным.

3.4 Зашумленный максимум (Report Noisy Max)

Определение 3.3 (Noisy Max). Пусть задан набор результатов $r_1, \dots, r_k$ и функция стоимости $u(X, r_i)$. Алгоритм работает следующим образом:

1. Для каждого i вычисляется значение

$$u_i = u(X, r_i).$$

2. К каждому значению добавляется независимый шум:

$$\eta_i \sim \text{Laplace}\left(0, \frac{2\Delta u}{\varepsilon}\right).$$

или

$$\eta_i \sim \text{Exponential}\left(\frac{2\Delta u}{\varepsilon}\right).$$

3. Возвращается результат

$$r^* = \arg \max_i (u_i + \eta_i).$$

Теорема 3.2. *Noisy Max* механизм является ε -дифференциально приватным.

См. приложения, сравнения экспоненциального и noisy max механизмов.

4 Продвинутые методы 2: Гауссовский шум, (ε, δ) -DP

4.1 (ε, δ) -дифференциальная приватность

Определение 4.1. Алгоритм A является (ε, δ) -дифференциально приватным, если для всех соседних X, X' и всех множеств S :

$$\Pr[A(X) \in S] \leq e^\varepsilon \Pr[A(X') \in S] + \delta.$$

4.2 Гауссовский механизм

Определение 4.2. Пусть f имеет L_2 -чувствительность $\Delta_2 f$. Гауссовский механизм:

$$A(X) = f(X) + \eta, \quad \eta \sim \mathcal{N}(0, \sigma^2 I),$$

где

$$\sigma \geq \frac{\sqrt{2 \ln(1.25/\delta)} \Delta_2 f}{\varepsilon}.$$

Теорема 4.1. Гауссовский механизм обеспечивает (ε, δ) -дифференциальную приватность.

Преимущества гауссовского шума

Для оценки качества модели будем использовать стандартную метрику — MSE (базовую для линейных моделей $f(X)$). d - размерность измерения, n - количество измерений.

4.2.1 Лапласовский шум

$$\Delta_1 = \sup_{X, X'} \|f(X) - f(X')\|_1 = \frac{d}{n}$$

$$Z_i \sim \text{Lap}\left(\frac{\Delta_1}{\varepsilon}\right) = \text{Lap}\left(\frac{d}{n\varepsilon}\right)$$

$$\text{MSE}_{\text{Lap}} \sim b^2 = \frac{d^2}{\varepsilon^2 n^2}$$

4.2.2 Гауссовский шум

$$\Delta_2 = \sup_{X, X'} \|f(X) - f(X')\|_2 = \frac{\sqrt{d}}{n}$$

$$Z_i \sim \mathcal{N}(\sigma^2) = \mathcal{N}\left(\frac{2\Delta_2^2}{\varepsilon^2} \log\left(\frac{1}{\delta}\right)\right) = \mathcal{N}\left(\frac{2d}{n^2\varepsilon^2} \log(n)\right)$$

$$\text{MSE}_{\text{Gauss}} \sim \sigma^2 \sim \frac{d \log(n)}{\varepsilon^2 n^2}$$

См. приложения, сравнение ε -DP Лапласова и Гауссова шумов.

Заключение


Мы рассмотрели:

- формальное определение DP;
- атаки, которые DP предотвращает;
- экспоненциальный механизм и зашумленный максимум;
- гауссовский механизм и (ε, δ) -DP.


Эти методы лежат в основе приватного машинного обучения и анализа данных, включая DP-SGD, приватные статистики и приватную выборку моделей.

5 Приложения

5.1 Сравнение экспоненциального механизма и механизма Noisy Max



5.2 Сравнение ε -DP Лапласова и Гауссова шумов. d - размерность измерения, n - количество измерений



Список литературы

- [1] С. Dwork, A. Roth, *The Algorithmic Foundations of Differential Privacy*, 2014.
- [2] GitHub репозиторий с кодом построения графиков из приложения:
MatveyMs/Modern-Cryptography-and-Confidential-AI